PYsemantic

中文语义分析工具 · Windows 便携版操作指南

适合第一次使用	完整解压压缩包，双击 PYsemantic.exe；在“01 数据准备”导入文本，在“02 方法设置”选择方法，然后开始分析。程序和内置 BGE 模型无需安装 Python，下载后可离线分析。

建议的操作顺序

- 先用压缩包中的 examples/synthetic_texts.csv 熟悉导入、计算和导出流程。它只包含自动编写的合成示例，不是研究数据。
- 确认每行、每段或每个文件分别代表什么，再选择文本列、ID 列与方法。
- 计算完成后检查原文、参数和导出记录；需要恢复时可保存项目。

便携版设备支持	本版包含 CPU 和 DirectML 运行时。CPU 是默认设备；DirectML 需要兼容的 GPU 与驱动。CUDA 运行时不包含在此 ZIP 中。首次启动可能较慢，因为 EXE 会先解压内置模型与运行库。

本指南按界面 01–05 页组织，截图来自真实 Windows 应用窗口。用于展示结果的文本由程序生成，仅说明操作位置，不代表任何数据分析结论。

01 数据准备：导入与清理

先确定分析单位，再导入文本。界面显示读取数量、空值排除与清理摘要，原始输入文件保持只读。

- 粘贴文本时选择切分方式：整段作为一篇、每行一篇，或按空行分成多篇；导入 TXT 文件也使用相同切分规则。
- 文件输入支持 TXT、CSV、TSV、XLSX 和 JSONL；TXT 目录会读取其中的文本文件。表格可指定文本列与 ID 列。
- 空文本会排除。重复 ID 会加后缀以保持唯一；只有勾选去重时才会按归一空白后的全文删除重复文本。
- 示例 CSV 的列名为 text 与 doc_id：选择文件后将 text 设为文本列、doc_id 设为 ID 列，再点“读取并清理”。



01 数据准备页。可粘贴文字、选择文件或读取 TXT 目录。

02 方法设置：选择表示与设备

方法会决定文本如何转成向量或词项矩阵。可先使用默认值完成一轮分析，再根据问题逐项调整参数。

方法	用途与提示
BGE-small-zh-v1.5	本地中文句向量；默认 CPU，可用 DirectML 时也可让 BGE 在 GPU 上运行。
词级 / 字符 TF-IDF	比较词项或字符组合的分布，适合作为可解释的词汇特征。
LSA / NMF / LDA	把词项矩阵分解成较少的潜在维度或主题；结果需要结合原文解释。
共现与 PPMI	汇总文档内一定窗口的词项共现，反映关联强度，不表示因果关系。
外部 word2vec	平均用户提供的文本向量；仅支持指定格式的文本向量文件。

- BGE 的设备选项只影响 BGE ONNX 推理；其它方法仍按各自的 CPU 实现计算。CPU 并行开关单独控制相关数值计算，默认关闭。
- 选择“自动使用可用 GPU”时会尝试可用的 provider 并回退到 CPU。显式选择 DirectML 要求驱动与设备可用；GPU 加速效果取决于语料规模。



02 方法设置页。截图显示默认 CPU 设置；页面下方还有分词、停词和计算参数。

开始分析与查看结果

选择需要的方法后点击“开始分析”。耗时计算在后台进行，任务页显示当前阶段和进度；任务完成后可在结果页按方法切换输出。

- 结果页包含概览、文档指标、词频、近邻、主题与聚类、相似度热图。双击文档或近邻行，或选中后按 Enter，可查看原文。
- 表格可按 ID、簇或相似度筛选，并按每页 50、100 或 300 条分页。完整导出不受界面预览行数限制。
- 完整文档相似度矩阵最多支持 1,500 篇文档；更大语料仍可按 Top-K 分块计算近邻。



03 结果查看页。截图使用六篇自动生成的合成文本，展示词级与字符级 TF-IDF 结果。

导出结果、保存项目与管理任务

- “导出选定结果”仅导出当前方法；“导出全部与比较表”导出所有已完成方法。选择父目录后，程序创建新的结果子目录。
- 结果包按方法包含适用的 UTF-8 CSV、NPZ 矩阵与轴标签、参数 JSON、数据处理记录和离线 HTML 报告；可勾选 XLSX。
- 点击“保存当前项目”会把语料文本、清理记录、设置和已完成结果写入所选文件夹。只有主动保存项目时，项目包才会包含原文。
- 任务页可打开已保存项目或历史结果、查看和导出日志、检查运行环境，以及保存/载入命名参数预设。设置 JSON 记录参数与路径，不会导入文本。



04 任务页上部。页面可向下滚动查看日志、项目、历史记录和参数预设。

05 帮助与方法资料

帮助页顶部提供“打开操作指南 PDF”和“另存操作指南”按钮。打开时使用 Windows 当前的 PDF 阅读器；另存可将手册复制到指定位置，便于归档或分享。

- “计算口径与方法”说明各指标、方法和资源限制。
- “来源文献”列出模型、方法与软件依据；点击文献链接会打开系统浏览器。
- “第三方许可”显示模型和运行依赖的许可信息。GPU 资料链接只有点击后才会打开浏览器。



05 帮助页。操作指南按钮位于其它方法、文献与许可链接之前。

结果解释、隐私与常见问题

结果表示的是选定方法与参数下的文本特征。余弦相似度不是概率、准确率或通用的重复判定阈值；聚类画像用于探索分组，主题和聚类都不是人工标注的真值。

计算范围	单次分析最多 20,000 篇文档、累计 2,000,000 个分析 token、单篇 100,000 个 token。完整相似度矩阵限于 1,500 篇文档；较大语料仍可使用分块近邻。超过范围时按界面提示拆分数据。

常见问题

- 首次启动较慢：单文件程序会先解压运行库和模型；之后启动通常更快。
- 无法分析或检查到缺少模型：请确认已完整解压，并重新下载完整压缩包。EXE 内置环境不能通过任务页的依赖安装按钮修改。
- DirectML 不可用：检查设备、驱动及环境页列出的 provider。自动模式会回退 CPU；显式 DirectML 在设备不兼容时会报错。
- 任务耗时较长：在“04 任务”查看阶段进度；可点击“取消”。部分模型调用需等当前批次完成后才停止。

隐私与本地文件

PYsemantic 在本机运行分析，不上传文本，也不会在启动时联网。运行日志和结果缓存保存在当前 Windows 用户的数据目录；普通运行日志不记录粘贴文本。主动导出结果或保存项目时才向用户选择的位置写入相应文件。项目包包含原始语料，保存与分享前请检查其中的数据。

离线分析使用内置 BGE 模型。程序不会自动下载模型；CUDA 或 DirectML 驱动、第三方 PDF 阅读器与外部浏览器属于本机环境。打开来源链接或 GPU 资料链接时，网络访问由用户点击启动的浏览器完成。

字体说明	本指南 PDF 嵌入了用于显示中文的 Noto Sans SC 字形子集。该字体版权归 Adobe，采用 SIL Open Font License 1.1；字体文件不作为单独文件随软件包分发。